

Данные

Данные были собраны из открытых источников и были преобразованы в файлы формата .txt. Ознакомиться с ними можно в репозитории гитхаба

Исследовательский вопрос

Цель проекта - проверить, можно ли с помощью методов компьютерного анализа текста выявить изменения в стиле и лексике произведений Эдуарда Лимонова разных периодов.

Основной исследовательский вопрос:

Как меняется лексико-стилевой профиль текстов Эдуарда Лимонова при сравнении нескольких произведений, написанных в разные периоды его творчества?

Этот вопрос можно проверить на данных, потому что тексты представлены в формате «.txt», а значит, их можно обработать программно: посчитать частотность слов, выделить ключевые слова и сравнить тексты между собой по частотным признакам.

Дополнительные вопросы:

1. Какие слова являются наиболее характерными для каждого текста?
2. Какие тексты оказываются ближе друг к другу по частотности словоформ?
3. Можно ли по результатам анализа говорить об изменении авторской манеры?

Предыдущие исследования

Творчество Эдуарда Лимонова часто рассматривается в связи с автобиографичностью, образом автора, эмигрантским опытом и соединением литературы с политическим жестом. Особенно часто в этом контексте упоминается роман «Это я - Эдичка», который воспринимается как важный текст русской автобиографической прозы и как произведение, где литературный герой тесно связан с публичным образом автора.

Исследователи также обращают внимание на литературные взгляды Лимонова, его отношение к русской литературе XX–XXI веков, андеграунду и понятию «жесточкого реализма». Это важно для нашего проекта, потому что стиль Лимонова связан не только с темами, но и с особой авторской позицией: резкостью, провокативностью, автобиографичностью и сознательным разрушением привычных литературных норм.

Методологически проект опирается на подходы цифровой гуманитаристики и текст-майнинга. TF-IDF используется для выделения слов, наиболее значимых для конкретного текста внутри корпуса. Этот метод позволяет увидеть не просто самые частотные слова, а слова, которые отличают один текст от других.

Для сравнения текстов по стилю используется стилометрический подход. В классической стилометрии важны частотные признаки текста: повторяющиеся словоформы, устойчивые языковые привычки, распределение наиболее частотных слов. Один из известных методов такого анализа - дельта Бёрроуза, предложенная Джоном Бёрроузом для измерения стилистического расстояния между текстами.

Таким образом, проект соединяет два уровня анализа: тематический, через TF-IDF, и стилометрический, через сравнение частотных профилей текстов.

Метод

В проекте используются два цифровых метода: TF-IDF и стилометрическое сравнение текстов.

Первый метод - TF-IDF. Он позволяет выделить ключевые слова каждого произведения. Обычная частотность показывает, какие слова встречаются чаще всего, но в таких списках часто оказываются слишком общие слова. TF-IDF работает точнее: он повышает вес слов, которые часто встречаются в одном тексте, но редко встречаются в других текстах корпуса. Поэтому этот метод подходит для поиска тематических и смысловых маркеров отдельных произведений.

Второй метод - стилометрический анализ. Для него тексты сравниваются по частотности словоформ. В отличие от TF-IDF, здесь важно не только содержание, но и повторяющиеся речевые привычки. На основе частотных профилей строится матрица расстояний между текстами: чем меньше расстояние, тем ближе тексты друг к другу; чем больше расстояние, тем сильнее они различаются.

Дополнительно используются визуализации: тепловая карта расстояний и дендрограмма. Тепловая карта показывает степень близости текстов друг к другу, а дендрограмма помогает увидеть, какие произведения группируются вместе.

Ход исследования

Сначала тексты были приведены к единому формату .txt. Затем они были загружены в Python через ссылки на GitHub. После этого была проведена предварительная обработка: удаление лишних символов, приведение текста к нижнему регистру, токенизация, лемматизация и удаление стоп-слов для TF-IDF.

На следующем этапе был рассчитан TF-IDF. Для каждого текста были выделены слова с наибольшим весом. Это позволило определить, какие лексические маркеры сильнее всего отличают одно произведение от других.

Затем была проведена стилометрическая часть анализа. Для нее тексты были очищены, но не лемматизированы, потому что в стилометрии важны именно словоформы. После этого была построена таблица частотности наиболее частотных словоформ, рассчитаны расстояния между текстами и создана визуализация.

Ограничения и перспективы

У проекта есть несколько ограничений. Во-первых, корпус текстов ограничен: анализируется только несколько произведений Лимонова, поэтому выводы нельзя автоматически распространять на всё его творчество. Во-вторых, разные тексты могут отличаться по объему, жанру и времени написания, а это влияет на результаты. Например, роман, дневниковая проза и публицистический текст могут различаться не только из-за эволюции стиля, но и из-за жанровых особенностей.

Еще одно ограничение связано с обработкой текста. Если из анализа удаляются стоп-слова, результат становится удобнее для интерпретации, но менее строгим с точки зрения классической стилометрии. Если стоп-слова оставить, анализ будет ближе к авторской атрибуции, но часть результатов будет выглядеть менее понятной для содержательного литературного анализа.

В дальнейшем проект можно расширить. Во-первых, можно добавить больше произведений Лимонова и разделить их по периодам: ранняя эмигрантская проза, постсоветские тексты, поздняя публицистика. Во-вторых, можно отдельно сравнить художественные тексты и публицистику. В-третьих, можно добавить другие методы: анализ длины предложений, частотность местоимений, n-граммы, тематическое моделирование или сравнение Лимонова с другими авторами русского андеграунда и эмигрантской литературы.

Главная перспектива проекта заключается в создании более широкой карты эволюции авторского письма Лимонова.

Результаты анализа

Как уже ранее было замечено, перед началом анализа важно учитывать объем самих текстов, так как размер произведения может влиять на частотные показатели. В нашем корпусе самым крупным текстом оказалась «История его слуги» (slugi) - 629 215 символов. Почти сопоставимым по объему является «Это я - Эдичка» (edichka) - 603 599

символов. Далее идет «Подросток Савенко» (Savenko) - 442 616 символов. Меньше по объему оказались «У нас была великая эпоха» (epoха) - 291 970 символов и «Дневник неудачника» (neudachnik) - 186 394 символа. Таким образом, корпус нельзя назвать полностью равномерным, однако все тексты достаточно объемные для того, чтобы проводить первичный частотный и стилометрический анализ.

После обработки корпуса была получена таблица из 20 409 лемм по пяти текстам. Это показывает, что тексты были загружены и обработаны корректно. В отличие от первоначального варианта, где часть файлов фактически не читалась программой как полноценный русский текст, теперь анализ уже можно использовать для содержательной интерпретации.

Частотный анализ показал, что у Лимонова в разных текстах повторяется общий набор слов: «свой», «мочь», «сказать», «человек», «который», «весь», «говорить», «знать», «время», «хотеть». С одной стороны, это довольно общая лексика, которая характерна для повествовательной прозы в целом. С другой стороны, в случае Лимонова она хорошо соотносится с автобиографическим характером его письма, так как в центре часто оказывается человек, его речь, желание, память, отношение к другим людям и к собственной жизни.

Вместе с этим, каждый текст имеет свои более выраженные лексические особенности. В «Подростке Савенко» среди частотных слов выделяются «светка», «кадик», «вовка», «ребята», «мать», «отец». Это позволяет говорить о том, что данный текст сильнее связан с миром детства, юности, семьи и дворового окружения. Здесь важны не абстрактные понятия, а конкретные люди и социальная среда, внутри которой формируется герой.

В «У нас была великая эпоха» наиболее заметными оказываются слова «мать», «отец», «ребёнок», «солдат», «лейтенант», «военный», «дивизия», «штаб». В этом случае частотный профиль уже указывает не только на семейную память, но и на военный контекст. Поэтому текст можно рассматривать как соединение автобиографического материала с более широким историческим и поколенческим сюжетом.

В «Это я - Эдичка» чаще встречаются слова «свой», «мочь», «сказать», «человек», «говорить», «знать», «хотеть», «елена», «русский», «жить», «жизнь», «любить». Такой набор хорошо отражает исповедальный характер текста. Здесь важны не только события, но и постоянное проговаривание собственного состояния, отношений, любви, эмигрантского опыта и столкновения героя с чужой социальной средой.

«Дневник неудачника или Секретная тетрадь» по частотному составу также оказывается связан с личной и эмоциональной тематикой. Среди наиболее частотных слов здесь встречаются «человек», «жизнь», «любить», «женщина», «друг», «девочка», «экономка», «день», «хороший». Это делает текст близким к дневниковой и рефлексивной прозе, где большое значение имеют отношения, быт и внутреннее состояние героя.

В «История его слуги» частотный анализ показывает заметное присутствие имен собственных и сюжетных маркеров: «дженни», «стивен», «линда», «гэтсби», «эдвард», «книга». Это отличает текст от более прямой автобиографической прозы. Он оказывается сильнее связан с системой персонажей и литературным сюжетом.

TF-IDF позволил уточнить эти наблюдения. Если простая частотность показывает самые употребительные слова, то TF-IDF выделяет те слова, которые особенно важны именно для данного текста по сравнению с остальными. Для «Подростка Савенко» такими словами стали «светка», «кадик», «вовка», «славка», «ребята», «саня», «салтовский», «костя». Это подтверждает, что данный текст выделяется локальной, семейной и подростково-дворовой лексикой.

Для «У нас была великая эпоха» ключевыми словами стали «мать», «отец», «ребёнок», «малышня», «солдат», «лейтенант», «дивизия», «штаб», «вениамин», «эдик». Здесь цифровой анализ хорошо показывает семейно-военный пласт текста. В центре оказывается не только личная память, но и историческая среда, связанная с войной и армией.

Для «Это я - Эдичка» среди наиболее значимых слов оказались «мочь», «сказать», «человек», «елена», «русский», «кирилл», «розанна», «жить», «жизнь», «любить». Это позволяет связать текст с исповедальностью, темой эмиграции, любовной травмой и постоянным самоописанием героя. Особенно важно появление слов «русский» и имен собственных, так как они указывают на связь личной истории с эмигрантской идентичностью и конкретным кругом отношений.

Для «Дневник неудачника или Секретная тетрадь» наиболее значимыми стали «человек», «жизнь», «любить», «женщина», «друг», «экономка», «девочка», «день», «хороший». Эти слова показывают, что текст держится на личном и бытовом материале. Здесь меньше выражена историческая или политическая линия, зато сильнее заметны темы любви, повседневности и человеческих отношений.

Для «История его слуги» ключевыми стали «дженни», «стивен», «линда», «гэтсби», «эдвард», «книга». Это показывает, что данный текст отличается от остальных именно персонажной и сюжетной лексикой. Поэтому его близость или удаленность от других произведений связана не только со стилем, но и с жанровой спецификой.

Стилометрический анализ также дал важный результат. Матрица расстояний показала, что наиболее близкими друг к другу оказались «Это я - Эдичка» и «Дневник неудачника или Секретная тетрадь»: расстояние между ними составило 0.489939. Это минимальное значение в таблице, следовательно, именно эти два текста наиболее похожи по частотности выбранных словоформ. Такой результат можно объяснить тем, что оба текста принадлежат к исповедальной и личной прозе Лимонова. В них важны речь героя, отношения, любовь, самоописание, жизнь в чужой или враждебной среде.

Достаточно близким к ним оказался и «История его слуги». Расстояние между «Это я - Эдичка» и «История его слуги» составило 0.542526, а между «Дневник неудачника или Секретная тетрадь» и «История его слуги» - 0.643517. Это значит, что «История его слуги», несмотря на более выраженную сюжетность и систему персонажей, все же оказывается ближе к исповедально-личной группе текстов, чем к «Подростку Савенко».

«У нас была великая эпоха» занимает промежуточное положение. С одной стороны, он не так близок к «Это я - Эдичка» и «Дневник неудачника или Секретная тетрадь», как они между собой. С другой стороны, он не отделяется от них полностью. Вероятно, это связано с тем, что текст сохраняет автобиографическую основу, но при этом включает

семейно-исторический и военный материал, который меняет его лексический профиль.

Самым обособленным текстом оказался «Подросток Савенко». Его расстояния до остальных текстов являются самыми высокими: 1.166735 до «Это я - Эдичка», 1.181651 до «У нас была великая эпоха», 1.173584 до «История его слуги» и 1.130614 до «Дневник неудачника или Секретная тетрадь». На дендрограмме это также хорошо видно: «Подросток Савенко» отделяется от остальных раньше всего. Это позволяет предположить, что его лексико-стилевой профиль наиболее самостоятельный. Скорее всего, это связано с тем, что в тексте сильнее выражена подростковая, семейная и локальная среда, а также большое количество имен и бытовых реалий.

Таким образом, результаты анализа показывают, что эволюция стиля Лимонова не выстраивается в простую линейную схему. Нельзя сказать, что один текст просто «ранний», другой «поздний», и между ними автоматически возникает движение от одного типа письма к другому. Скорее внутри корпуса видны разные лексико-стилевые группы. «Это я - Эдичка» и «Дневник неудачника или Секретная тетрадь» образуют наиболее близкую исповедально-личную группу. «История его слуги» частично примыкает к ней, но отличается более выраженной персонажной и сюжетной лексикой. «У нас была великая эпоха» соединяет автобиографическое письмо с семейной памятью и военным контекстом. «Подросток Савенко», наоборот, оказывается наиболее отдельным текстом, так как в нем сильнее проявлена лексика детства, семьи, двора и конкретного социального окружения.

Вместе с этим, результаты анализа следует рассматривать осторожно. Используемые методы хорошо показывают частотные и лексические

различия, но они не могут полностью объяснить стиль автора без литературоведческой интерпретации. Кроме того, корпус включает только пять текстов, а сами произведения отличаются по объему и жанру. Поэтому полученные выводы лучше понимать как предварительную цифровую карту различий внутри прозы Лимонова, а не как окончательное доказательство эволюции его стиля.

Список литературы:

1. Гурленова Л. В. Э. Лимонов о литературе («Это я - Эдичка») // Вестник Череповецкого государственного университета. 2012. № 2. Т. 2. С. 72–75.
2. «Да, смерть!» А Лимонов жив // The Blueprint. URL: <https://theblueprint.ru/culture/paper/eto-ya-edichka> (дата обращения: 17.06.2026).
3. Burrows J. «Delta»: A Measure of Stylistic Difference and a Guide to Likely Authorship // Literary and Linguistic Computing. 2002. Vol. 17, № 3. P. 267–287. DOI: 10.1093/lc/17.3.267.
4. Lavin M. Analyzing Documents with TF-IDF // Programming Historian. 2019. № 8. DOI: 10.46430/phen0082. URL: <https://programminghistorian.org/en/lessons/analyzing-documents-with-tfidf> (дата обращения: 17.06.2026).

5. Silge J., Robinson D. Text Mining with R: A Tidy Approach. Chapter 3: Analyzing Word and Document Frequency: TF-IDF. URL: https://www.tidytextmining.com/tfidf (дата обращения: 17.06.2026).


6. Karsdorp F., Kestemont M., Riddell A. Humanities Data Analysis: Case Studies with Python. Chapter: Stylometry and the Voice of Hildegard. URL: https://www.humanitiesdataanalysis.org/stylometry/notebook.html (дата обращения: 17.06.2026).

7. Always1ready. 4_stylometry.ipynb // GitHub: dh-tools. URL: https://github.com/always1ready/dh-tools/blob/main/04_seminar/4_stylometry.ipynb (дата обращения: 17.06.2026).


8. Always1ready. 4_tf_idf_labwork.ipynb // GitHub: dh-tools. URL: https://github.com/always1ready/dh-tools/blob/main/04_seminar/4_tf_idf_labwork.ipynb (дата обращения: 17.06.2026).

Приложения:

Кластеризация текстов Лимонова по стилю



Стилометрическое расстояние между текстами Лимонова





	Savenko	edichka	epoha	neudachnik	slugi
Savenko	0.000000	1.166735	1.181651	1.130614	1.173584
edichka	1.166735	0.000000	0.814487	0.489939	0.542526
epoha	1.181651	0.814487	0.000000	0.820641	0.871202
neudachnik	1.130614	0.489939	0.820641	0.000000	0.643517
slugi	1.173584	0.542526	0.871202	0.643517	0.000000

Частотность 100 самых частотных словоформ в текстах Лимонова

